Proyecto Final de Fundamentos de Programación

Cruz Quispe Luis Angel
Escuela de Ingeniería Física
Universidad Nacional de Ingeniería
Facultad de Ciencias 20221664C

Rios Cusi Pedro David
Escuela de Ingeniería Física
Universidad Nacional de Ingeniería
Facultad de Ciencias 20230216J

Mamani Benites Jimmy
Escuela de Ingeniería Física
Universidad Nacional de Ingeniería
Facultad de Ciencias 20211489D

***Resumen*— Este proyecto explora el análisis de datos, machine learning y visualización utilizando las bibliotecas de Python Pandas, Matplotlib y NumPy. Pandas facilita la manipulación de datos tabulares, Matplotlib permite crear diversos gráficos, y NumPy es fundamental para operaciones numéricas eficientes. Se incluyen ejercicios prácticos que demuestran la integración y aplicabilidad de estas herramientas en el análisis y visualización de datos.**

I. INTRODUCCION

Este proyecto explora herramientas y técnicas clave de análisis de datos, machine learning, procesamiento de lenguaje natural, desarrollo web y automatización. Utilizamos las librerías de Python Pandas, Matplotlib y NumPy para la manipulación y visualización de datos.

II. MARCO TEORICO

II-A. Librerías

Panda:

Es una biblioteca de análisis de datos que proporciona estructuras de datos de alto nivel y herramientas para trabajar con datos estructurados o tabulares. Aquí están los puntos clave:

I. **Dataframe:** Es la estructura central en Pandas, que representa datos en forma de tablas con filas y columnas etiquetadas. Los DataFrames permiten manipular datos de manera similar a una hoja de cálculo.

II. **Series:** Es otra estructura importante en Pandas, que representa una columna unidimensional en un DataFrame, junto con un índice.

III. **Operaciones de datos:** Pandas ofrece funcionalidades poderosas para limpiar, transformar, fusionar y analizar datos. Esto incluye manipulaciones de datos como filtros, agregaciones, agrupaciones y pivoteo.

II-B. Librerías

***Matplotlib*:**

Es la biblioteca estándar para visualización de datos en Python. Ofrece una variedad de funciones para crear gráficos estáticos, gráficos interactivos, subplots y más. Los aspectos destacados son:

I. **Estilos de gráficos**: Permite crear una amplia gama de gráficos, incluyendo gráficos de líneas, barras, dispersión, histogramas, diagramas de caja y más.

II. **Personalización**: Ofrece control completo sobre la apariencia de los gráficos, incluyendo colores, marcadores, leyendas, etiquetas de ejes y títulos.

III. **Subplots y figuras multiples**: Permite crear múltiples gráficos dentro de la misma figura y personalizar su disposición.

IV. **Interactividad**: A través de otras bibliotecas como mpld3 o Plotly, Matplotlib puede ser utilizada para crear gráficos interactivos y widgets en notebooks de Jupyter.

II-C. Librerías

Numpy:

Es la biblioteca fundamental para la computación científica en Python. Proporciona soporte para arrays multidimensionales (llamados ndarray), junto con una amplia colección de funciones matemáticas para operar en estos arrays. Algunos conceptos clave incluyen:

I. **Arrays:** Son estructuras de datos fundamentales en NumPy, que permiten almacenar datos de manera eficiente y realizar operaciones vectorizadas.

II. **Operaciones vectorizadas**: NumPy permite realizar operaciones rápidas en arrays completos sin necesidad de bucles explícitos, lo cual es crucial para la eficiencia en el procesamiento de datos.

III. **Funciones matemáticas**: Proporciona funciones para operaciones matemáticas

IV. básicas y avanzadas, como funciones trigonométricas, álgebra lineal, estadísticas y más.

V. **Indexación y segmentación avanzadas**: Permite acceder y manipular datos dentro de arrays utilizando técnicas poderosas de indexación y segmentación.

III. DESARROLLO

Aquí haremos presencia de los códigos de los respectivos de los ejercicios planteados en los cuadernos compartidos en github:

1. 1.1 Ejercicios del cuaderno de Pandas:

3.1.1

```python
#Ejercicio
'''
Agrega las columnas siguientes: edad_mas_5, nombre_completo y genero
edad_mas_5viene de sumar 5 a la etiqueta edad
nombre_completo viene de sumar las etiquetas primer_nombre, _ y ultimo_nombre
genero es una serie de elementos 'F','F','M','M','M','F'.
'''
import pandas as pd

data1 = {
    'primer_nombre': ['Amy', 'Amy', 'Jason', 'Nick', 'Stephen', 'Amy'],
    'ultimo_nombre': ['Jackson', 'J', 'Miller', 'Milner', 'L', 'J'],
    'edad': [42, 42, 36, 24, 24, 42]
}
#creo un dataframe de pandas a partir de los datos de data1
df = pd.DataFrame(data1, columns=['primer_nombre', 'ultimo_nombre', 'edad'])

df['edad_mas_5'] = df['edad'] + 5

df['nombre_completo'] = df['primer_nombre'] + ' ' + df['ultimo_nombre'].replace('J', '')

genero = ['F', 'F', 'M', 'M', 'M', 'F']
df['genero'] = genero

# Mostrar el DataFrame resultante
print(df)
```

```
  primer_nombre ultimo_nombre  edad  edad_mas_5 nombre_completo genero
0           Amy       Jackson    42          47     Amy Jackson      F
1           Amy             J    42          47             Amy      F
2         Jason        Miller    36          41    Jason Miller      M
3          Nick        Milner    24          29     Nick Milner      M
4       Stephen             L    24          29       Stephen L      M
5           Amy             J    42          47             Amy      F
```

3.1.2

```
Suma por nombres:
                Estado Genero        Edad       Salario
Nombre
jack    SFONYKNYKSFO   ABCC  155.328124  16232.724189
jane      SFOCANYKCA   AABA  159.593494  17122.763963

Edad máxima y salario máximo por nombre/estado:
                     Edad      Salario
                      max          max
Nombre Estado
jack   NYK      47.312864  4368.362251
       SFO      36.490052  4471.500728
jane   CA       39.831228  4695.501317
       NYK      44.415005  4773.738279
       SFO      41.791620  3897.427799
```

```python
import pandas as pd
import numpy as np

df = pd.DataFrame({
    'Nombre': ['jack', 'jane', 'jack', 'jane', 'jack', 'jane', 'jack', 'jane'],
    'Estado': ['SFO', 'SFO', 'NYK', 'CA', 'NYK', 'NYK', 'SFO', 'CA'],
    'Edad': np.random.uniform(24, 50, size=8)
})

#df.groupby(['Estado', 'Nombre']) agupamos datos de variable estado y nombre
tabla_grupo = df.groupby(['Estado', 'Nombre'])['Edad'].mean().reset_index()
#mean() Esto calcula la media de las edades
#.reset_index() : Esto convierte los índices de los grupos (Estado y Nombre) en columnas regulares
#   y restablece el índice del DataFrame para que sea numérico, comenzando desde 0.

edad_media_estado = df.groupby('Estado')['Edad'].mean()

print("Edad media por Estado:")
print(edad_media_estado)
```

3.1.3

```python
import pandas as pd
import numpy as np

df = pd.DataFrame({'Nombre': ['jack', 'jane', 'jack', 'jane', 'jack', 'jane', 'jack', 'jane'],
                   'Estado': ['SFO', 'SFO', 'NYK', 'CA', 'NYK', 'NYK', 'SFO', 'CA'],
                   'Genero': ['A', 'A', 'B', 'A', 'C', 'B', 'C', 'A'],
                   'Edad': np.random.uniform(24, 50, size=8),
                   'Salario': np.random.uniform(3000, 5000, size=8)})

suma_por_nombres = df.groupby('Nombre').sum()
#se está utilizando el método groupby de pandas para agrupar los datos del DataFrame df
#por la columna 'Nombre'. Después, se aplica el método sum() sobre los grupos resultantes.

print("Suma por nombres:")
print(suma_por_nombres)
print()
agregaciones = {
    'Edad': ['max'],
    'Salario': ['max']
}
maximos_por_nombre_estado = df.groupby(['Nombre', 'Estado']).agg(agregaciones)

print("Edad máxima y salario máximo por nombre/estado:")
print(maximos_por_nombre_estado)
```

```
Edad media por Estado:
Estado
CA     45.423754
NYK    39.778021
SFO    37.896553
Name: Edad, dtype: float64
```

3.2 Ejercicios del cuaderno de Numpy:

3.2.1

```python
import numpy as np
#genero numeros aleatorios
np.random.seed(0)

x1 = np.random.randint(10, size=6)
x2 = np.random.randint(10, size=(5, 4))
x3 = np.random.randint(10, size=(2, 4, 5))
print("Atributos de x1:")
print("Dimensiones (ndim):", x1.ndim)
print("Forma (shape):", x1.shape)
print("Tamaño (size):", x1.size)
print("Tipo de datos (dtype):", x1.dtype)
print("Tamaño de cada elemento (itemsize):", x1.itemsize)
print("Tamaño total en bytes (nbytes):", x1.nbytes)
print()
print("Atributos de x2:")
print("Dimensiones (ndim):", x2.ndim)
print("Forma (shape):", x2.shape)
print("Tamaño (size):", x2.size)
print("Tipo de datos (dtype):", x2.dtype)
print("Tamaño de cada elemento (itemsize):", x2.itemsize)
print("Tamaño total en bytes (nbytes):", x2.nbytes)
print()
print("Atributos de x3:")
print("Dimensiones (ndim):", x3.ndim)
print("Forma (shape):", x3.shape)
print("Tamaño (size):", x3.size)
print("Tipo de datos (dtype):", x3.dtype)
print("Tamaño de cada elemento (itemsize):", x3.itemsize)
print("Tamaño total en bytes (nbytes):", x3.nbytes)
```

```
Atributos de x1:
Dimensiones (ndim): 1
Forma (shape): (6,)
Tamaño (size): 6
Tipo de datos (dtype): int64
Tamaño de cada elemento (itemsize): 8
Tamaño total en bytes (nbytes): 48

Atributos de x2:
Dimensiones (ndim): 2
Forma (shape): (5, 4)
Tamaño (size): 20
Tipo de datos (dtype): int64
Tamaño de cada elemento (itemsize): 8
Tamaño total en bytes (nbytes): 160

Atributos de x3:
Dimensiones (ndim): 3
Forma (shape): (2, 4, 5)
Tamaño (size): 40
Tipo de datos (dtype): int64
Tamaño de cada elemento (itemsize): 8
Tamaño total en bytes (nbytes): 320
```

3.2.2

```python
import numpy as np
#creo una matriz
matriz = np.array([[ 0,  1,  2,  3],
                   [ 4,  5,  6,  7],
                   [ 8,  9, 10, 11]])

print("Matriz original:")
print(matriz)
print()
submatriz = matriz[:2, 1:3]

print("Submatriz extraída (primeras 2 filas y columnas 1 y 2):")
print(submatriz)
print()
submatriz[0, 0] = 99

print("Submatriz después de modificar submatriz[0, 0] a 99:")
print(submatriz)
print()
print("Matriz original después de modificar la submatriz:")
print(matriz)
```

```
Matriz original:
[[ 0  1  2  3]
 [ 4  5  6  7]
 [ 8  9 10 11]]

Submatriz extraída (primeras 2 filas y columnas 1 y 2):
[[1 2]
 [5 6]]

Submatriz después de modificar submatriz[0, 0] a 99:
[[99  2]
 [ 5  6]]

Matriz original después de modificar la submatriz:
[[ 0 99  2  3]
 [ 4  5  6  7]
 [ 8  9 10 11]]
```

3.3 Ejercicios del cuaderno de matplotlib:

3.3.1

```python
import matplotlib.pyplot as plt
import numpy as np
# creo arreglo de valores numericos
x = np.linspace(start=-5, stop=5, num=150)
# creo una figura que contiene un arreglo de subplots
fig, axs = plt.subplots(2, 2, figsize=(10, 8))

axs[0, 0].plot(x, x, label='Lineal')
axs[0, 0].set_title('Función Lineal')
axs[0, 1].plot(x, x**2, label='Cuadrático')
axs[0, 1].set_title('Función Cuadrática')
axs[1, 0].plot(x, x**3, label='Cúbico')
axs[1, 0].set_title('Función Cúbica')
axs[1, 1].plot(x, x**4, label='4ta Potencia')
axs[1, 1].set_title('Función 4ta Potencia')

# Ajustar espacio ente subplots
plt.tight_layout()
for ax in axs.flat:
    ax.legend()  # se muestran las leyendas

plt.show()
```

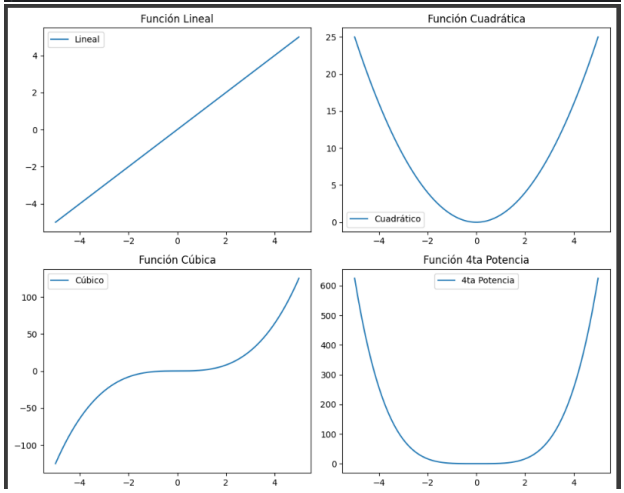

3.3.2

```python
import matplotlib.pyplot as plt

plt.plot([1, 2, 3, 2.5])
plt.ylabel('Valores')
plt.show()
```

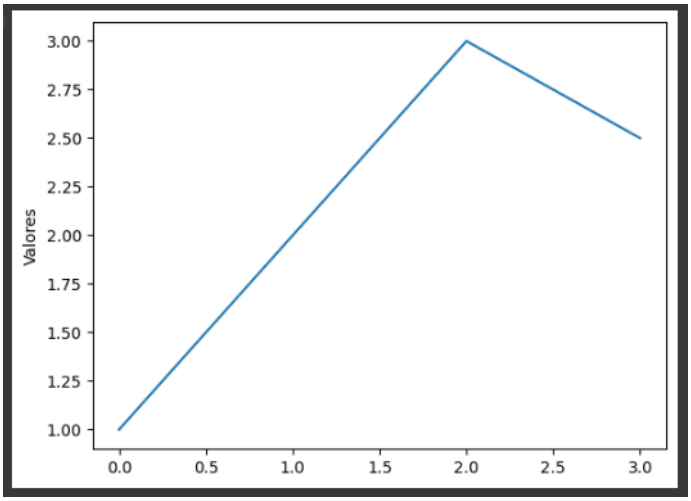

3.3.3

```python
import numpy as np
import matplotlib.pyplot as plt
x = np.linspace(start=-2, stop=2, num=400)
fig, ax = plt.subplots(figsize=(10, 6))
for N in range(1, 11):
    #establesco "colores"
    ax.plot(x, x**N, label=f'x^{N}')
ax.set_title(r'$x$ hasta $N$, donde $N=1,\ldots,10$')
ax.legend()
plt.grid(True)
plt.show()
```

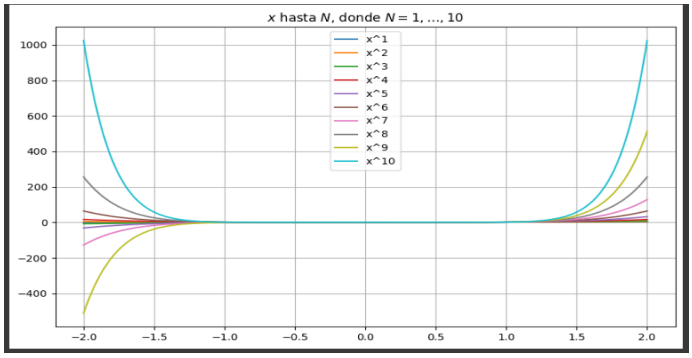

3.3.4

```python
import numpy as np
import matplotlib.pyplot as plt
x = np.linspace(-3.5, 3.5, 400)
seno = np.sin(x)
coseno = np.cos(x)
fig, ax = plt.subplots()
#ponemos "colores"
ax.plot(x, seno, color='red', label='Seno')
ax.plot(x, coseno, color='#165181', label='Coseno')
#limites de eje
ax.set_xlim(-3.5, 3.5)
ax.set_ylim(-1.2, 1.2)
#establesco tiks
ax.set_xticks([-np.pi, -np.pi/2, 0, np.pi/2, np.pi])
ax.set_yticks(np.arange(-1, 1.1, 0.5))
ax.set_xticklabels(['$-\pi$', r'$-\frac{\pi}{2}$', '0', r'$\frac{\pi}{2}$', r'$\
ax.set_yticklabels(['-1.0', '-0.5', '0', '0.5', '1.0'])
ax.legend()
plt.show()
```

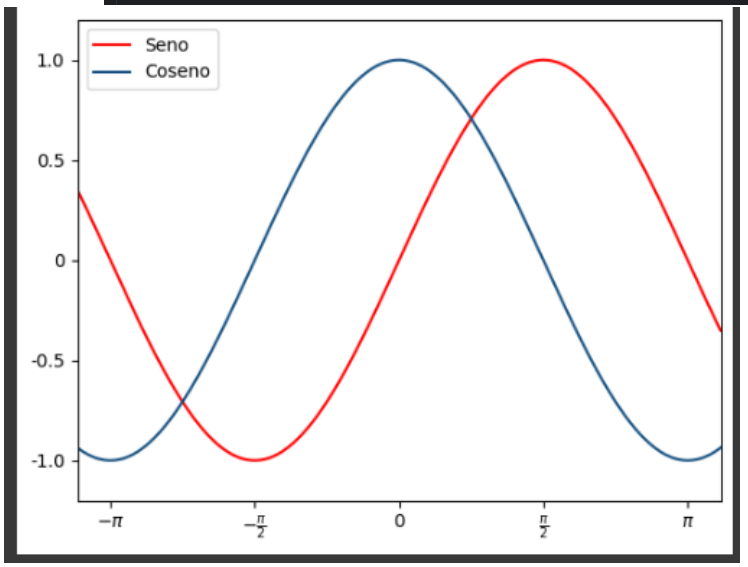

3.3.5

```python
import numpy as np
import matplotlib.pyplot as plt
x = np.linspace(-3.5, 3.5, 400)
seno = np.sin(x)
coseno = np.cos(x)
fig, ax = plt.subplots()
ax.plot(x, seno, color='red', label='Seno')
ax.plot(x, coseno, color='#165181', label='Coseno')
ax.set_xlim(-3.5, 3.5)
ax.set_ylim(-1.2, 1.2)
ax.set_xticks([-np.pi, -np.pi/2, 0, np.pi/2, np.pi])
ax.set_yticks(np.arange(-1, 1.1, 0.5))
ax.set_xticklabels(['$-\pi$', r'$-\frac{\pi}{2}$', '0', r'$\frac{\pi}{2}$', r'$\pi$'])
ax.set_yticklabels(['-1.0', '-0.5', '0', '0.5', '1.0'])
#agregamos leyendas
ax.legend()
ax.text(-3, 0.75, 'Seno', color='red', fontsize=12, ha='left', va='center')
ax.text(-3, -0.75, 'Coseno', color='#165181', fontsize=12, ha='left', va='center')
plt.show()
```

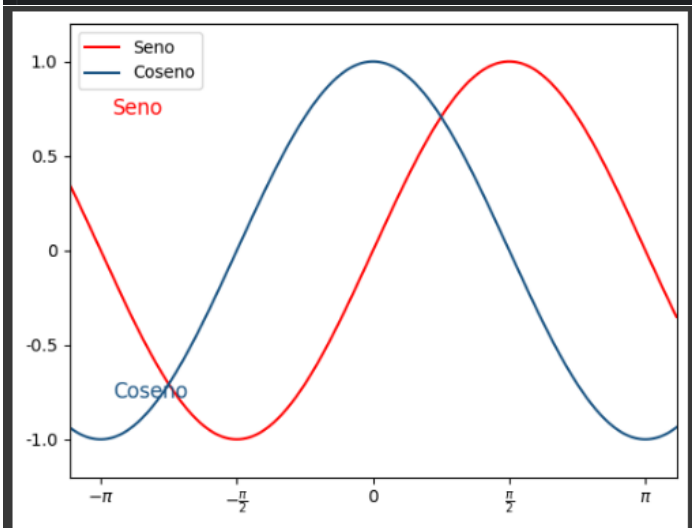

3.3.6

```python
import numpy as np
import matplotlib.pyplot as plt

x = np.linspace(-3.5, 3.5, 400)
seno = np.sin(x)
coseno = np.cos(x)

fig, ax = plt.subplots()
ax.plot(x, seno, color='green', label='Seno')
ax.plot(x, coseno, color='#341161', label='Coseno')
ax.set_xlim(-3.5, 3.5)
ax.set_ylim(-1.2, 1.2)

ax.set_xticks([-np.pi, -np.pi/2, 0, np.pi/2, np.pi])
ax.set_yticks([-1, 0, 1])

ax.set_xticklabels([r'$-\pi$', r'$-\pi/2$', r'$0$', r'$+\pi/2$', r'$+\pi$'], size=17)
ax.set_yticklabels(['-1', '0', '+1'], size=17)
ax.legend(loc='upper left')
ax.text(-0.25, 0, '(0,0)')
ax.text(np.pi - 0.25, 0, r'$(\pi,0)$', size=15)
ax.annotate('Origen', xy=(0, 0), xytext=(1, -0.7), arrowprops=dict(facecolor='blue'))
plt.show()
```

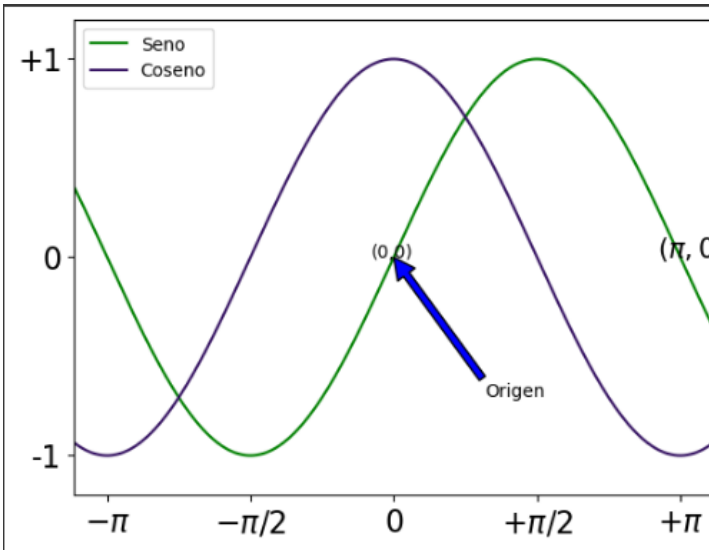

3.3.7

```python
import matplotlib.pyplot as plt
import numpy as np
x = np.linspace(0, 50, 100)
y1 = np.sin(x)
y2 = np.cos(x)
fig, ax = plt.subplots()
ax.plot(x, y1, label='Seno')
ax.set_xlabel('Etiqueta x en los ejes', fontsize=12)
ax.set_ylabel('Etiqueta y en los ejes', fontsize=12)
ax.legend()
fig.tight_layout(pad=2.0)

# Mostrar el gráfico
plt.show()
```

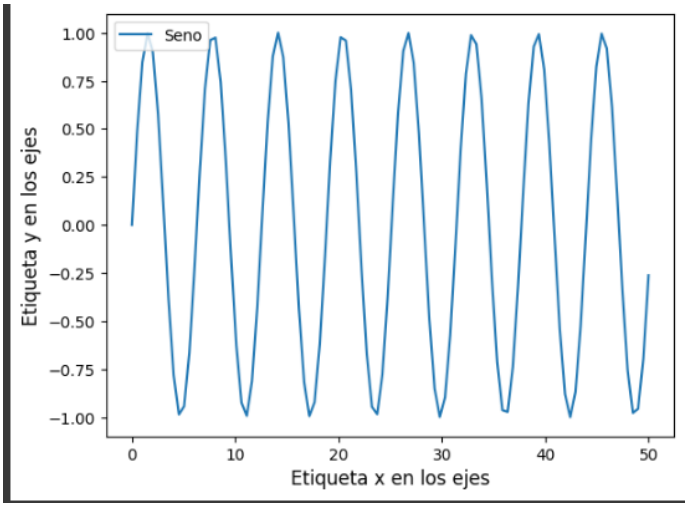

I. CONCLUSIONES

En conclusión, las bibliotecas NumPy, Pandas y Matplotlib se presentan como pilares fundamentales en el ecosistema de Python para el análisis de datos y la visualización.

NumPy proporciona la base eficiente para operaciones numéricas en arrays multidimensionales, esencial para el procesamiento de datos a gran escala. Por otro lado, Pandas simplifica significativamente la manipulación y el análisis de datos tabulares mediante sus estructuras de datos flexibles como DataFrames y Series, permitiendo operaciones complejas con facilidad.

Finalmente, Matplotlib destaca por su capacidad para crear una amplia variedad de gráficos estáticos y interactivos, ofreciendo control detallado sobre la apariencia visual de los datos.

La integración fluida entre estas bibliotecas facilita un flujo de trabajo coherente y eficiente desde la carga de datos hasta su análisis y visualización, convirtiéndolas en herramientas indispensables para cualquier profesional o investigador que trabaje con datos en Python.

V. BIBLIOGRAFÍA

McKinney, W. (2017). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and IPython*. O'Reilly Media.

The pandas development team. (2020). *pandas-dev/pandas: Pandas*. Zenodo. doi:10.5281/zenodo.3509134

The matplotlib development team. (2020). *matplotlib/matplotlib: Matplotlib*. Zenodo. doi:10.5281/zenodo.3893